# 딥러닝 파이토치 교과서 5장 - Part 1

## 5.1 합성곱 신경망

- 역전파: 순전파 과정에 따라 계산된 오차 정보가 신경망의 모든 노드(1️⃣출력층2️⃣은닉층3️⃣입력층)로 전송됨.
    - 위와 같은 계산 과정은 복잡하고 많은 지원을 요구함

    ➡️ **위 문제를 해결하고자 합성곱 신경망이 제안됨**

    - 이미지 전체를 한 번에 계산하는 것이 아니라, 이미지의 국소적(한정된 영역) 부분을 계산
    - 시간과 자원을 절약, 이미지의 세밀한 부분까지 분석

### 5.1.1 합성곱층의 필요성

- 합성곱 신경망의 도입

그림 5-1 합성곱층 원리

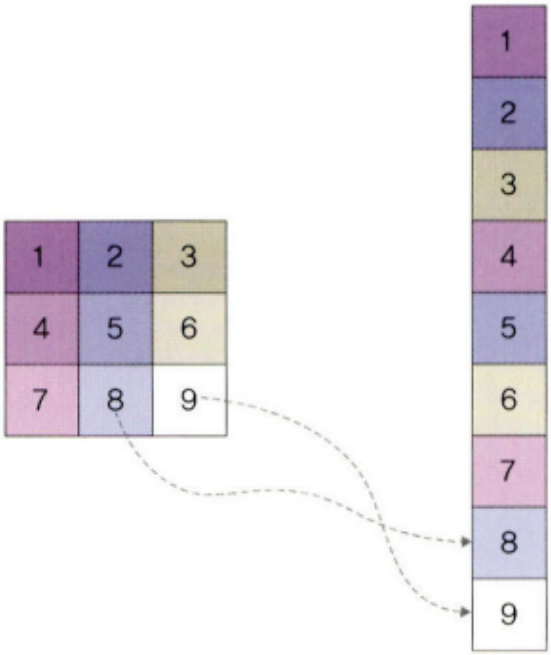


- 이미지 flattening 후 각 픽셀에 가중치를 곱하여 은닉층으로 전달
- flattening을 할 경우 데이터의 공간적 구조를 무시하게 되는 문제 발생
- 이를 방지하기 위해 **합성곱층 도입**

## 5.1.2 합성곱 신경망 구조

- 합성곱 신경망 구조

그림 5-2 합성곱 신경망 구조

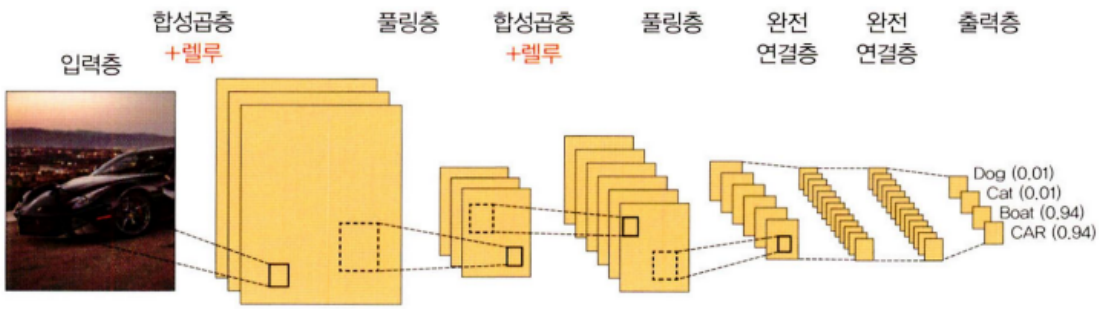

- 음성 인식이나 이미지, 영상 인식에서 주로 사용
- 다차원 배열 데이터 처리하도록 구성 >> 컬러 이미지 같은 다차원 배열 처리에 특화
- 다섯 개의 계층으로 구성됨
- 합성곱층&풀링층을 거치면서 입력 이미지의 주요 특성 벡터(feature vector)를 추출
- 추출된 주요 특성 벡터들은 완전연결층을 거치면서 1차원 벡터로 변환됨
- 출력층에서 활성화 함수인 소프트맥스 함수를 사용하여 최종 결과 출력
-

### 1️⃣ 입력층

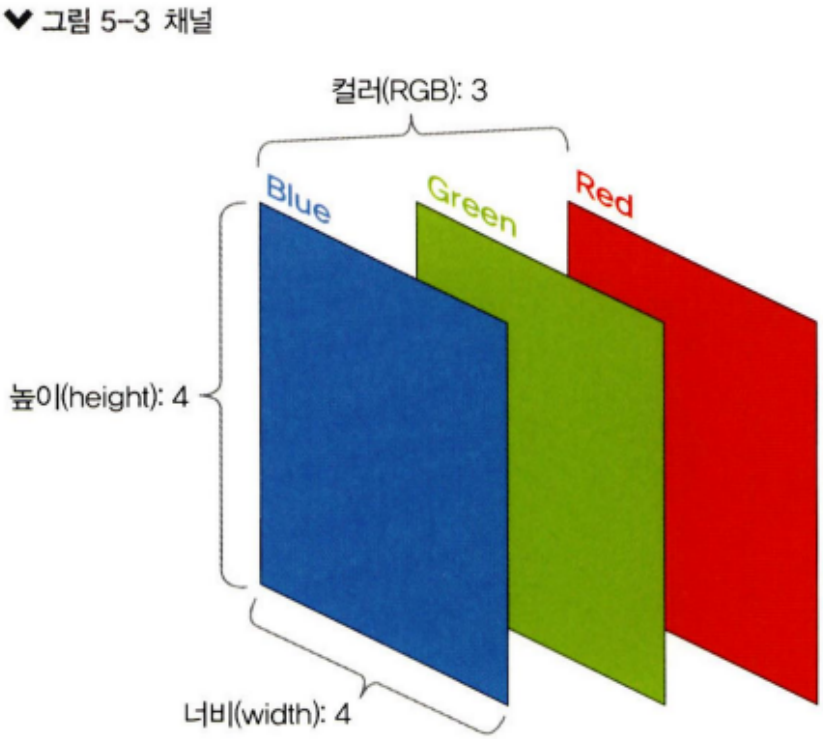


- 이미지 데이터가 **최초**로 거치게 되는 계층
- 높이, 너비, 채널의 값을 갖는 **3차원 데이터**
  - 이미지가 gray scale이면 채널값=1
  - 이미지가 RGB이면 채널값=3
  - 높이4, 너비4, RGB채널인 이미지일 경우 이미지 shape는 (4, 4, 3)으로 표현

## 2️⃣ 합성곱층

- 입력 데이터에서 **특성 추출**
- 입력 이미지가 들어왔을 때 이미지에 대한 **특성을 감지**하는 용도로 **kernel이나 필터**를 사용
- 커널이나 필터는 **이미지의 모든 영역**을 훑으면서 특성을 추출 >> 추출된 결과물은 **특성 맵 (feature map)**
  - 커널은 3x3, 5×5 크기로 적용되는 것이 일반적
  - 스트라이드(필터를 적용하는 위치의 간격)라는 지정된 간격에 따라 순차적으로 이동
- (6, 6, 1) 크기의 gray scale 이미지 & 3x3 커널/필터가 스트라이드 1 간격으로 이동하면서 합성곱 연산을 수행하는 과정

  **1) 입력 이미지에 3x3 필터 적용**

  입력 이미지와 필터를 포개고 대응되는 숫자끼리 곱한 후 모두 더함

❮ 그림 5-4 입력 이미지에 3×3 필터 적용

  **2) 필터가 1만큼 이동**

❮ 그림 5-5 입력 이미지에 필터가 1만큼 이동

### 3) 필터가 1만큼 두 번째 이동

❮ 그림 5-6 입력 이미지에 필터가 1만큼 두 번째 이동

### 6) 필터가 1만큼 마지막으로 이동

❮ 그림 5-9 입력 이미지에 필터가 1만큼 마지막으로 이동

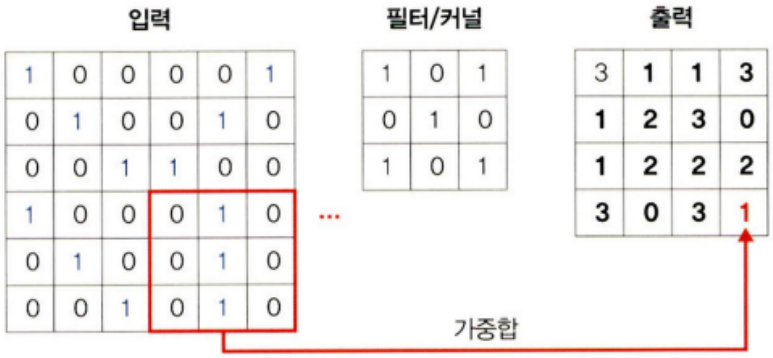

커널은 스트라이드 간격만큼 순회하면서 모든 입력 값과의 합성곱 연산으로 새로운 특성 맵을 생성

커널과 스트라이드의 상호작용으로 (6, 6, 1) 크기가 (4, 4, 1) 크기의 특성 맵으로 줄어들었음

- 컬러 이미지의 합성곱

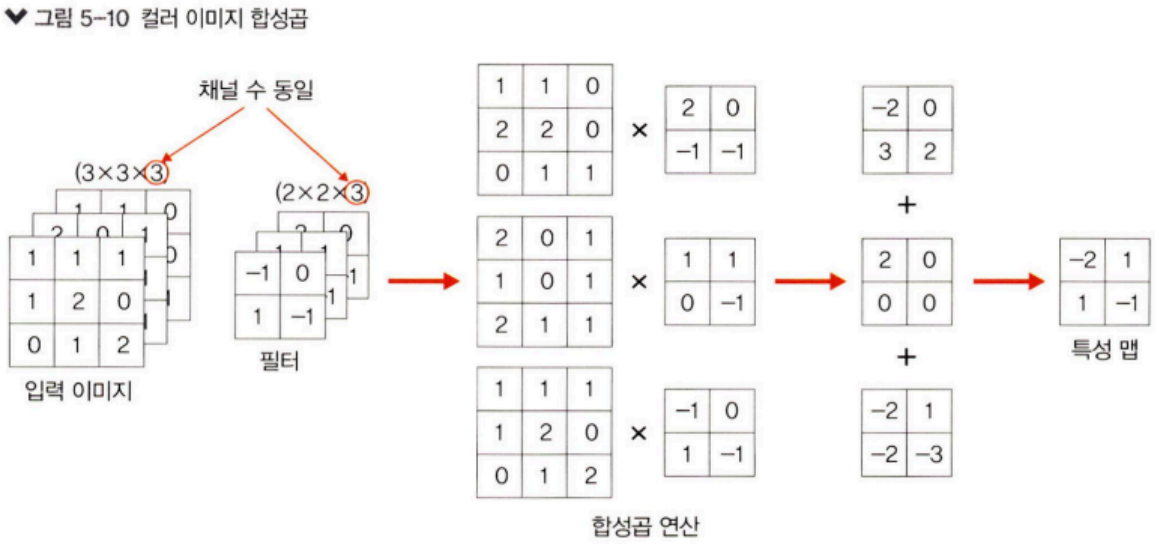


  - 필터 채널이 3
  - RGB 각각에 서로 다른 가중치로 합성곱을 적용한 후 결과를 더해 줌
  - 필터 채널 3개 ≠ 필터 개수 3개 (실제로 필터 개수는 1개)

- 필터가 2개 이상인 합성곱

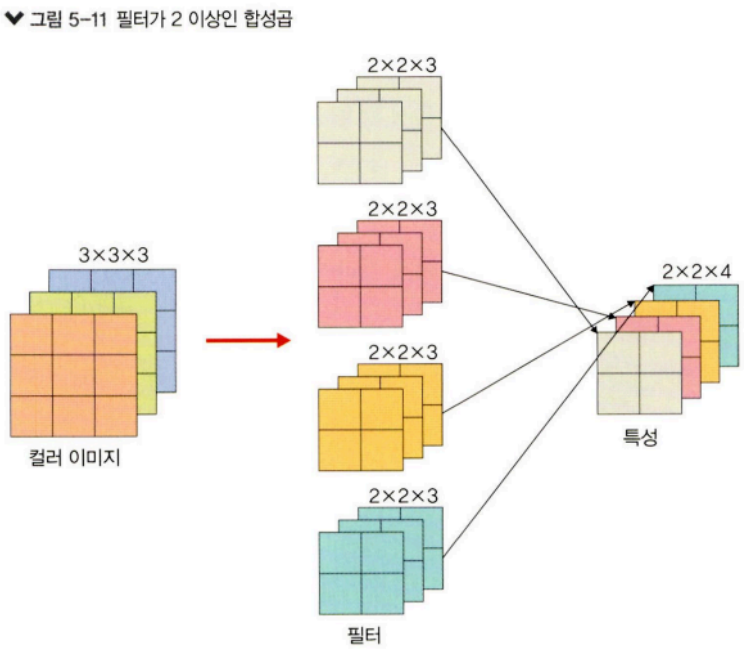


  - 필터 각각은 특성 추출 결과의 채널이 됨
  -
- 합성곱층 요약
  - 입력 데이터: 가로 W_1x세로 H_1x채널(깊이) D_1
  - 하이퍼파라미터: 필터 개수 K, 필터 크기 F, 스트라이드 S, 패딩 P
  - 출력 데이터
    - 특성맵 W_2 = (W_1-F+2P)/S+1
    - 특성맵 H_2 = (H_1-F+2P)/S+1
    - 특성맵 D_2 = K

- 3️⃣ **풀링층**
- 합성곱층과 유사하게 특성 맵의 차원을 **다운샘플링**(축소)하여 연산량을 감소시킴
- 주요한 특성 벡터를 추출하여 학습을 효과적으로 할 수 있도록 함
- 최대 풀링과 평균 풀링 두 가지 연산이 사용됨
  - **최대 풀링**: 대상 영역에서 최댓값 추출

- **평균 풀링**: 대상 영역에서 평균을 반환
- 대부분의 합성곱 신경망에서는 최대 풀링을 사용
- 평균 풀링은 각 커널 값을 평균화시켜 중요한 가중치를 갖는 값의 특성이 희미해질 수 있기 때문에 잘 사용되지 않음
  처

- 최대 풀링의 연산 과정

  1) 첫 번째 최대 풀링 과정

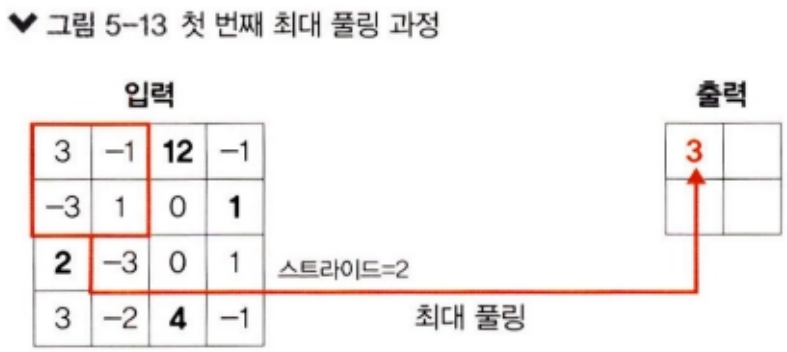


  2) 두 번째 최대 풀링

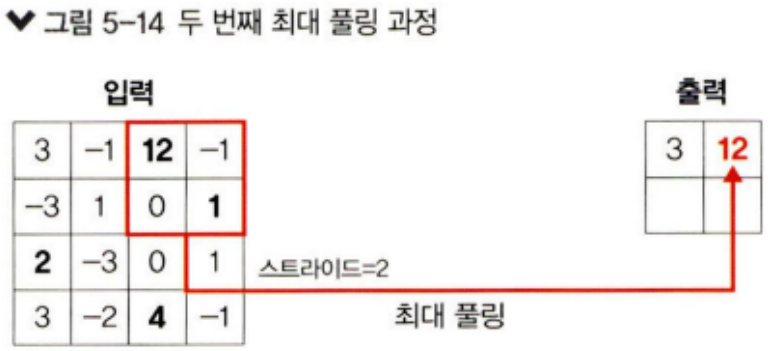


  3) 세 번째 최대 풀링 과정

- 최대 풀링 vs 평균 풀링

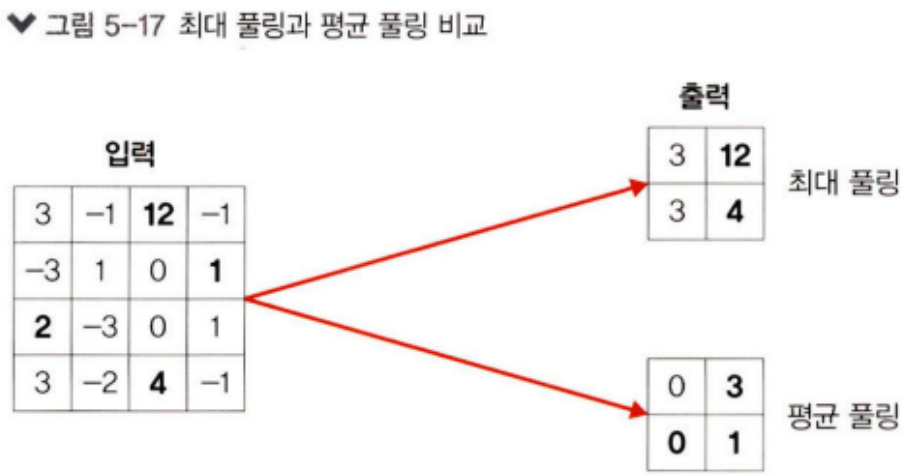


- 풀링층 요약
  - 입력 데이터: 가로 W_1x세로 H_1x채널(깊이) D_1
  - 하이퍼파라미터: 필터 크기 F, 스트라이드 S
  - 출력 데이터
    - W_2 = (W_1-F)/S+1
    - H_2 = (H_1-F)/S+1
    - D_2 = D_1

## 4️⃣ 완전연결층

❮ 그림 5-18 완전연결층

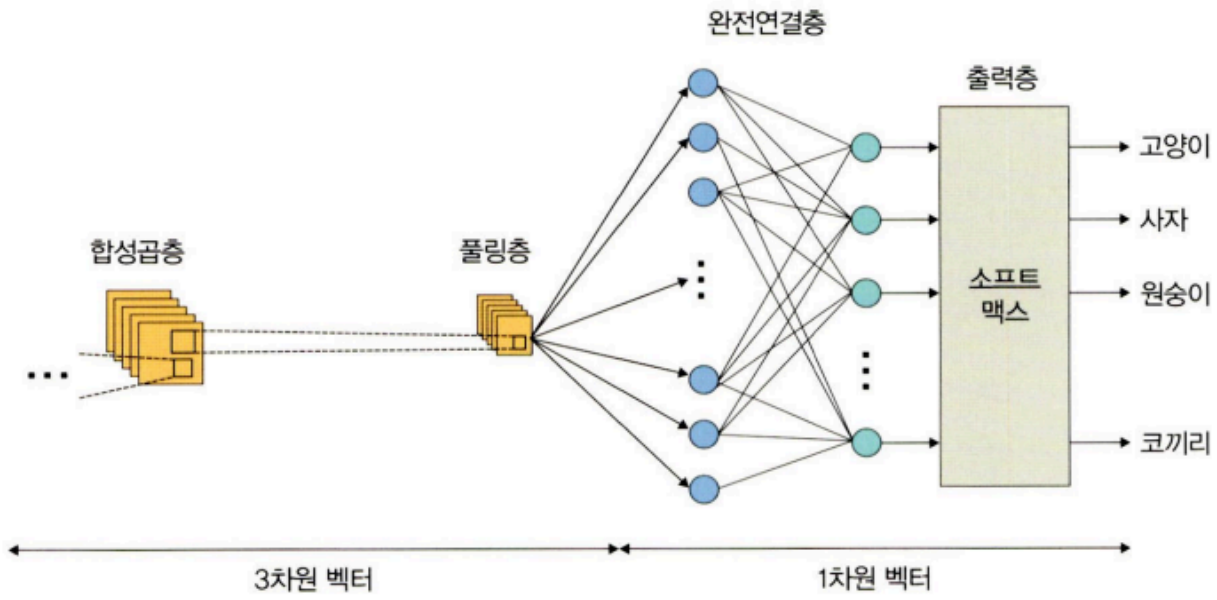


- 합성곱층과 풀링층을 거치면서 차원이 축소된 특성 맵은 최종적으로 완전연결층(fully connected layer)으로 전달됨
- 해당 층에서 이미지는 3차원 벡터에서 1차원 벡터로 flattening됨
-

**5️⃣ 출력층**

- 소프트맥스 활성화 함수 사용
- 입력받은 값을 0~1 사이의 값으로 출력
- 이미지가 각 레이블에 속할 확률 값 출력
- 가장 높은 확률 값을 갖는 레이블이 최종 값으로 선정됨

## 5.1.3 1D, 2D, 3D 합성곱

- 합성곱은 **이동하는 방향의 수**와 **출력 형태**에 따라 1D, 2D, 3D로 분류할 수 있음

**1️⃣ 1D 합성곱**

❮ 그림 5-19 1D 합성곱

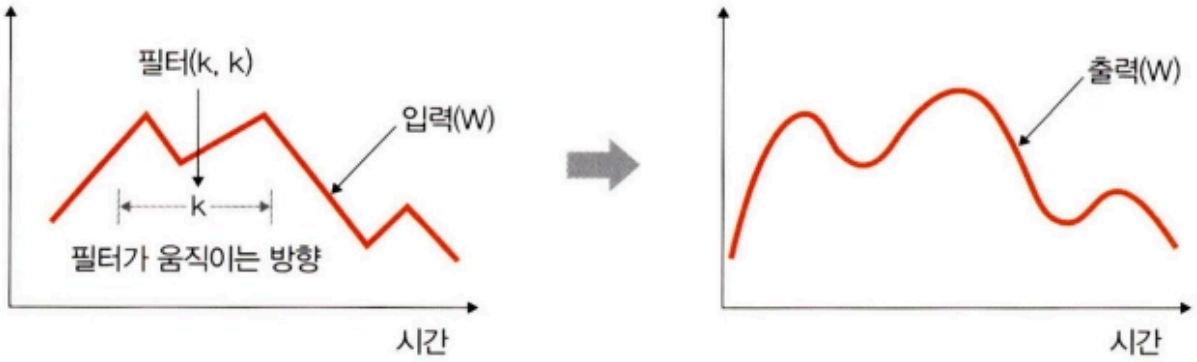


- 입력: W 너비(Width)
- 필터: k×k(높이×너비)
- 출력: W 너비(Width)

- 필터가 시간을 축으로 좌우로만 이동할 수 있는 합성곱
- 입력W과 필터k에 대한 출력은 W
    - 입력이 [1, 1, 1, 1], 필터가 [0.25, 0.5, 0.25] >> 출력 [1, 1, 1]
- 출력 형태는 1D의 배열
- 그래프 곡선을 완화할 때 많이 사용

### 2️⃣ 2D 합성곱

❮ 그림 5-20 2D 합성곱

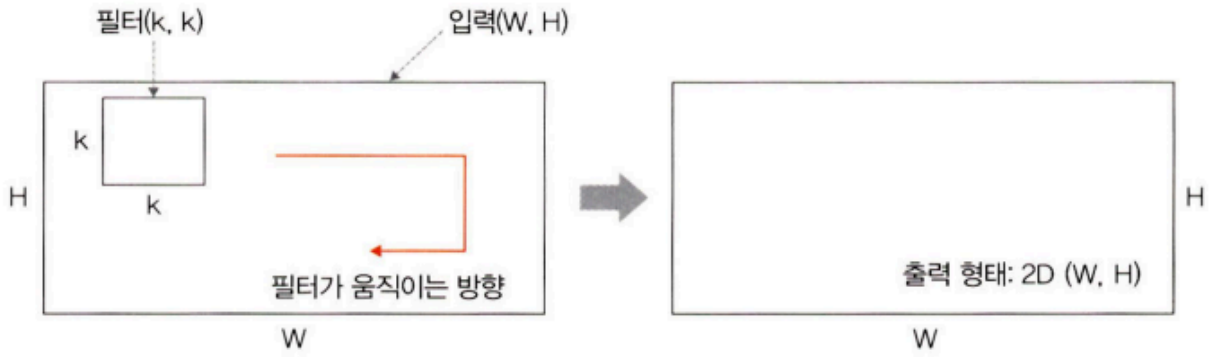


- 입력: W 너비(Width), H 높이(Height)
- 필터: k×k(높이×너비)
- 출력: W 너비(Width), H 높이(Height)

- 필터가 두 개의 방향으로 움직이는 형태
- 입력(W, H), 필터(k, k) >> 출력 (W, H)
- 출력 형태는 2D 행렬

## 3 3D 합성곱

❮ 그림 5-21 3D 합성곱

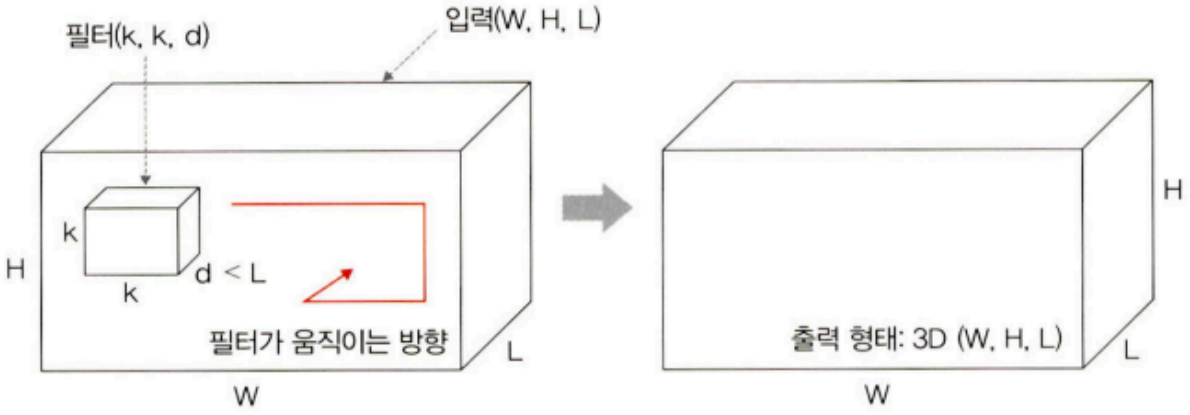


- 입력: W 너비(Width), H 높이(Height), L 길이(Length)
- 필터: k×k(높이×너비), d: 깊이(depth)
- 출력: W 너비(Width), H 높이(Height), L 길이(Length)

- 필터가 세 개의 방향으로 움직이는 형태
- 입력(W, H, L), 필터(k, k, d) >> 출력(W, H, L)
- 출력 형태는 3D
- d < L을 유지하는 것이 중요

## 4️⃣ 3D 입력을 갖는 2D 합성곱

❮ 그림 5-22 3D 입력을 갖는 2D 합성곱

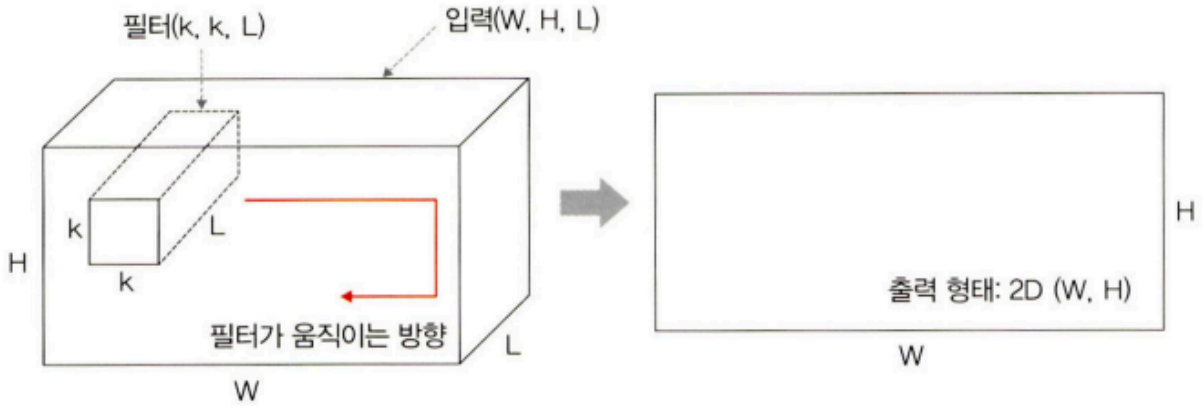


- 입력: W 너비(Width), H 높이(Height), L 길이(Length)
- 필터: k×k(높이×너비), L 길이(Length)
- 출력: W 너비(Width), H 높이(Height)

- 입력이 3D 형태임에도 출력 형태가 2D 행렬인 경우
- 필터에 대한 길이(L)가 입력 채널의 길이(L)와 같아야 함
- 입력(W, H, L), 필터(k, k, L) >> 출력(W, H)
- 필터가 두 방향으로 움직이며 출력 형태는 2D 행렬

## 5️⃣ 1×1 합성곱

❮ 그림 5-23 1×1 합성곱

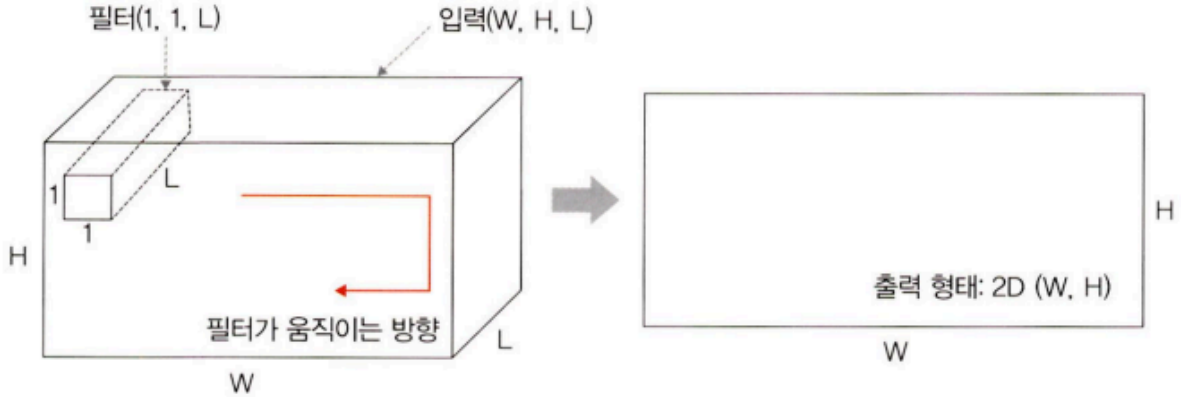


- 입력: W 너비(Width), H 높이(Height), L 길이(Length)
- 필터: 1×1(높이×너비), L 길이(Length)
- 출력: W 너비(Width), H 높이(Height)

- 3D 형태로 입력
- 입력(W, H, L), 필터(1, 1, L) >> 출력(W, H)
- 1×1 합성곱에서 채널 수를 조정 >> 연산량 감소 효과(GoogLeNet)